

Descrição da atividade

A base *Student Performance* contém informações pessoais, familiares e escolares de estudantes. Classifique cada variável como **qualitativa** ou **quantitativa**. Em seguida, informe o seu subtipo: **nominal**, **ordinal**, **discreta** ou **contínua**.

ID	Variável	Descrição	Tipo		Subtipo
1	school	Escola do estudante: GP ou MS.	☐ Quali	☐ Quanti	
2	sex	Sexo do estudante: feminino ou masculino.	☐ Quali	☐ Quanti	
3	age	Idade do estudante, entre 15 e 22 anos.	☐ Quali	☐ Quanti	
4	address	Residência urbana ou rural.	☐ Quali	☐ Quanti	
5	famsize	Família com até três pessoas ou mais de três pessoas.	☐ Quali	☐ Quanti	
6	Pstatus	Pais vivendo juntos ou separados.	☐ Quali	☐ Quanti	
7	Medu	Escolaridade da mãe, codificada de 0 a 4.	☐ Quali	☐ Quanti	
8	Fedu	Escolaridade do pai, codificada de 0 a 4.	☐ Quali	☐ Quanti	
9	Mjob	Ocupação da mãe.	☐ Quali	☐ Quanti	
10	Fjob	Ocupação do pai.	☐ Quali	☐ Quanti	
11	reason	Motivo da escolha da escola.	☐ Quali	☐ Quanti	
12	guardian	Responsável pelo estudante.	☐ Quali	☐ Quanti	
13	traveltime	Faixa de tempo de deslocamento até a escola.	☐ Quali	☐ Quanti	
14	studytime	Faixa de tempo semanal de estudo.	☐ Quali	☐ Quanti	
15	failures	Número de reprovações anteriores.	☐ Quali	☐ Quanti	
16	schoolsup	Apoio educacional oferecido pela escola: sim ou não.	☐ Quali	☐ Quanti	
17	famsup	Apoio educacional oferecido pela família: sim ou não.	☐ Quali	☐ Quanti	
18	paid	Aulas particulares pagas: sim ou não.	☐ Quali	☐ Quanti	
19	activities	Participação em atividades extracurriculares: sim ou não.	☐ Quali	☐ Quanti	
20	nursery	Frequentou a educação infantil: sim ou não.	☐ Quali	☐ Quanti	
21	higher	Pretende cursar o ensino superior: sim ou não.	☐ Quali	☐ Quanti	
22	internet	Possui acesso à internet em casa: sim ou não.	☐ Quali	☐ Quanti	
23	romantic	Está em um relacionamento amoroso: sim ou não.	☐ Quali	☐ Quanti	
24	famrel	Qualidade das relações familiares, avaliada de 1 a 5.	☐ Quali	☐ Quanti	
25	freetime	Nível de tempo livre após as aulas, avaliado de 1 a 5.	☐ Quali	☐ Quanti	
26	goout	Frequência de saída com amigos, avaliada de 1 a 5.	☐ Quali	☐ Quanti	
27	Dalc	Nível de consumo de álcool durante a semana, avaliado de 1 a 5.	☐ Quali	☐ Quanti	
28	Walc	Nível de consumo de álcool no final de semana, avaliado de 1 a 5.	☐ Quali	☐ Quanti	
29	health	Estado de saúde atual, avaliado de 1 a 5.	☐ Quali	☐ Quanti	
30	absences	Número de faltas escolares.	☐ Quali	☐ Quanti	
31	G1	Nota do primeiro período, variando de 0 a 20.	☐ Quali	☐ Quanti	
32	G2	Nota do segundo período, variando de 0 a 20.	☐ Quali	☐ Quanti	
33	G3	Nota final, variando de 0 a 20.	☐ Quali	☐ Quanti	

Questões iniciais

Use o DataFrame importado no Python e responda:

- Qual é a dimensão do DataFrame?
- Existem valores ausentes no DataFrame? Em caso afirmativo, quantos?
- Considere como população as notas **G1** dos estudantes da escola GP.
 - Calcule a média populacional de **G1**.
 - Organize aleatoriamente os valores da população e construa amostras acumuladas de tamanhos $n = 1, 2, 3, \dots, N$,
em que N representa o tamanho total da população.
 - Para cada tamanho amostral n , calcule a média amostral $\bar{x}_n$.
 - Construa um gráfico de linhas contendo:
 - no eixo horizontal, o tamanho da amostra;
 - no eixo vertical, a média amostral acumulada;
 - uma linha horizontal representando a média da população.
 - Com base no gráfico, descreva o comportamento da média amostral à medida que o tamanho da amostra aumenta. A estimativa se torna mais estável? O que ocorre quando $n = N$?
- Repita o procedimento alterando o valor da semente utilizada em **random_state**. Por exemplo, utilize as sementes 10, 42 e 100. Construa novamente o gráfico para cada semente e compare os resultados.
 - As médias amostrais apresentam o mesmo comportamento?
 - Em quais tamanhos de amostra as diferenças são mais evidentes?
 - O último valor da média acumulada muda quando a semente é alterada?
 - Explique por que a alteração da semente modifica a trajetória do gráfico, mas não modifica a média final.
- Simulação de Monte Carlo e viés da média amostral**

Considere todos os valores da variável **G1** como uma população finita.

 - Calcule a média populacional de **G1**, representada por μ_{G1} .
 - Retire aleatoriamente uma amostra de tamanho $n = 50$, sem reposição, e calcule sua média amostral.

- Repita o procedimento anterior 1 000 vezes, armazenando a média obtida em cada repetição.
- Calcule a média das 1 000 médias amostrais.
- Calcule o viés aproximado da média amostral:

$$\widehat{B}_{MC}(\bar{X}) = \overline{\bar{X}}_{MC} - \mu_{G1}.$$

Nessa expressão, $\overline{\bar{X}}_{MC}$ representa a média das médias amostrais obtidas nas 1 000 repetições.

- Construa um histograma das médias amostrais. Indique no gráfico:
 - a média populacional μ_{G1} ;
 - a média das estimativas $\overline{\bar{X}}_{MC}$.
- Com base nos resultados obtidos, responda:
 - A média das estimativas ficou próxima de μ_{G1} ?
 - O viés aproximado ficou próximo de zero?
 - O histograma das médias amostrais parece estar centrado em torno de μ_{G1} ?
 - As médias obtidas foram iguais em todas as amostras? Explique por que elas variam.
 - Os resultados da simulação são compatíveis com a afirmação de que $\bar{X}$ é um estimador não viesado de μ_{G1} ?

6. Outras médias

- Construa um gráfico apresentando a média aparada para cada tamanho amostral. Acrescente duas linhas horizontais, representando:
 - a média aparada da população;
 - a média aritmética da população.
- Compare o comportamento da média aritmética com o comportamento da média aparada. Qual delas parece apresentar menor sensibilidade aos valores extremos? Justifique com base nos gráficos obtidos.

8. Mesmo centro, diferentes dispersões

Considere os dois conjuntos de dados:

$$A = \{4, 5, 6, 7, 8\} \quad B = \{0, 5, 6, 7, 12\}.$$

- Calcule a média e a mediana de cada conjunto.
- Verifique se os dois conjuntos possuem o mesmo centro.
- Calcule o desvio absoluto médio de cada conjunto:

$$\text{DAM} = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|.$$

- Calcule o desvio absoluto mediano de cada conjunto:

$$\text{MAD} = \text{Mediana}(|x_i - \tilde{x}|).$$

- Qual dos conjuntos apresenta maior dispersão?
- O DAM e o MAD apresentaram o mesmo comportamento? Explique.

9. Influência de um valor extremo

Considere inicialmente:

$$C = \{2, 4, 6, 8, 10\}.$$

Agora substitua o último valor por uma observação extrema:

$$C^* = \{2, 4, 6, 8, 100\}.$$

- Calcule a média e a mediana de C e de C^* .
- Calcule o DAM dos dois conjuntos.
- Calcule o MAD dos dois conjuntos.
- Compare as alterações sofridas pela média e pela mediana.
- Compare as alterações sofridas pelo DAM e pelo MAD.
- Qual medida de dispersão foi menos sensível ao valor extremo? Explique por que isso ocorreu.

10. DAM e MAD nas notas G1

Considere todos os valores da variável **G1** como uma população finita.

- Calcule a média populacional de **G1**.
- Calcule a mediana populacional de **G1**.
- Calcule o desvio absoluto médio:

$$\text{DAM}_{G1} = \frac{1}{N} \sum_{i=1}^N |x_i - \mu_{G1}|.$$

- Calcule o desvio absoluto mediano:

$$\text{MAD}_{G1} = \text{Mediana}(|x_i - \tilde{x}_{G1}|).$$

- Interprete os resultados utilizando a unidade original da variável, isto é, pontos na nota.
- Qual é a principal diferença entre a interpretação do DAM e a interpretação do MAD?

11. Um experimento com contaminação

Crie uma cópia da variável **G1** e substitua apenas uma observação pelo valor 100. Esse valor será utilizado apenas como um erro artificial para o experimento.

- Calcule, para os dados originais e para os dados contaminados:
 - a média;
 - a mediana;
 - o DAM;
 - o MAD.
- Organize os resultados em uma tabela.
- Quais medidas apresentaram as maiores alterações?
- Quais medidas permaneceram mais estáveis?
- Explique por que não seria correto excluir automaticamente uma nota baixa ou alta legítima apenas porque ela influencia as medidas.

12. Do módulo ao quadrado

Utilizando novamente os dados originais e os dados contaminados, calcule:

$$Q = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2.$$

- Compare o valor de Q nos dados originais e nos dados contaminados.
- Compare a alteração de Q com as alterações do DAM e do MAD.
- Por que o valor 100 apresenta um impacto tão grande quando os desvios são elevados ao quadrado?
- Qual é a unidade de medida de Q ?
- Qual seria uma possível vantagem de utilizar o quadrado em vez do módulo?

13. Padronização das notas G1

Considere os valores observados da variável **G1**.

- Calcule a média $\bar{x}_{G1}$ e o desvio padrão amostral s_{G1} das notas.
- Padronize cada nota utilizando:

$$z_i = \frac{x_i - \bar{x}_{G1}}{s_{G1}}.$$

- Acrescente os valores padronizados ao banco de dados em uma nova coluna chamada **G1_padronizada**.
- Calcule a média e o desvio padrão amostral da variável **G1_padronizada**.
- Verifique se os resultados ficaram aproximadamente iguais a:

$$\bar{z} = 0 \quad s_z = 1.$$

- Interprete os seguintes casos:
 - $z_i = 0$;
 - $z_i = 1$;
 - $z_i = -2$.
- Identifique:
 - o estudante com o maior valor padronizado;
 - o estudante com o menor valor padronizado;
 - os estudantes cujas notas estão a mais de dois desvios padrão da média.
- Construa dois histogramas:
 - um para a variável original **G1**;
 - outro para a variável **G1_padronizada**.
- Compare os dois histogramas. A padronização modificou o formato da distribuição ou apenas seu centro e sua escala? Justifique.
- Explique por que a padronização pode ser importante quando **G1** é utilizada juntamente com variáveis medidas em escalas muito diferentes.